



ESCUELA  
POLITÉCNICA  
SUPERIOR

# Monitorización de personas mayores con una pulsera inteligente para estimación de la fragilidad



Grado en Ingeniería Biomédica

## Trabajo de fin de Grado

Autor:

Luz Denny Ramirez Hurtado

Tutores:

Francisco Florez Revuelta

Pau Climent Perez



Universitat d'Alacant  
Universidad de Alicante



# Monitorización de personas mayores con una pulsera inteligente para estimación de la fragilidad

---

## Autor

Luz Denny Ramirez Hurtado

## Tutor/es

Francisco Asis Florez Revuelta  
*Tecnología Informática y Computación*

Pau Climent Perez  
*Tecnología Informática y Computación*



Grado en Ingeniería Biomédica



Escuela  
Politécnica  
Superior



Universitat d'Alacant  
Universidad de Alicante

ALICANTE, Julio 2025



# Justificación

La fragilidad constituye un síndrome geriátrico de elevada relevancia clínica, caracterizado fundamentalmente por una disminución de la reserva fisiológica del individuo y, consecuentemente, por un incremento en la vulnerabilidad ante la aparición de eventos adversos para la salud, tales como caídas, hospitalizaciones o la pérdida de autonomía funcional [1]. La detección temprana de este estado se establece como un elemento esencial para la implementación de intervenciones precoces y estrategias personalizadas que fomenten un envejecimiento activo y saludable en la población anciana, lo que se traduce en una mejora considerable de su calidad de vida y una posible disminución de la carga asistencial sobre los sistemas de salud [2][3].

Sin embargo, los métodos tradicionales empleados en la evaluación de la fragilidad, presentar limitaciones considerables en su implementación a gran escala y en condiciones no clínicas. Con frecuencia, estos métodos requieren la realización de pruebas presenciales, la intervención de profesionales sanitarios especializados y la administración de cuestionarios que introducen un elemento de subjetividad en el proceso de evaluación [4].

Los smartwatches ofrecen una solución prometedora al permitir la monitorización continua y no invasiva de parámetros relevantes, como la velocidad de la marcha, la variabilidad cardíaca y el sedentarismo [5]. Este TFG analiza el potencial de los smartwatches como herramientas accesibles y objetivas para la detección temprana de la fragilidad, con el objetivo de innovar en el ámbito de la salud digital y la geriatría, facilitando así la intervención temprana y la telemedicina personalizada.

# **Agradecimientos**

En primer lugar, estos agradecimientos son para mis padres, Henry y Leticia, por estar siempre ahí, en las buenas y en las malas, apoyándome, cuidándome y viendo por mí.

A quien se ha convertido en parte imprescindible de mi vida y que siempre está conmigo, ayudándome y siendo la mejor compañía que he tenido, Itzar

***"La vida es lo que pasa mientras estás ocupado haciendo otros planes."***

*— John Lennon*





# Resumen

La fragilidad es un síndrome geriátrico caracterizado por una disminución en la reserva fisiológica y una mayor vulnerabilidad ante eventos adversos, como caídas o pérdida de autonomía. La detección temprana de la fragilidad resulta esencial para fomentar un envejecimiento activo y reducir la carga asistencial. Sin embargo, los métodos tradicionales de evaluación son limitados, ya que requieren entornos clínicos y personal especializado. En este Trabajo de Fin de Grado se propone una metodología para estimar el estado de fragilidad en personas mayores a través de datos obtenidos de un smartwatch comercial. Se recopilieron métricas relacionadas con la actividad física, el sueño, la frecuencia cardíaca y la temperatura cutánea, las cuales fueron analizadas mediante un modelo de aprendizaje automático (XGBoost). Además, se desarrolló una aplicación web interactiva que permite la predicción automática del estado de fragilidad. Los resultados mostraron una precisión del 93.33%, confirmando la viabilidad del uso de tecnologías vestibles como herramientas de monitorización continua y no invasiva, con potencial aplicación en salud preventiva y telemedicina.

**Palabras clave:** Fragilidad, Smartwatch, Machine Learning, XGBoost, Salud digital, Personas mayores, Monitorización.

# Abstract

Frailty is a geriatric syndrome defined by reduced physiological reserve and increased vulnerability to adverse health outcomes, such as falls or loss of autonomy. Early detection is essential to promote healthy aging and reduce healthcare burden. However, traditional assessment methods are limited by their reliance on clinical settings and trained personnel. This Final Degree Project proposes a methodology to estimate frailty status in older adults using data collected from a commercial smartwatch. Metrics related to physical activity, sleep quality, heart rate, and skin temperature were analyzed using a machine learning model (XGBoost). An interactive web application was also developed to enable automatic frailty prediction. The model achieved an accuracy of 93.33%, supporting the feasibility of wearable technology as a continuous and non-invasive monitoring tool with potential applications in preventive healthcare and telemedicine.

**Keywords:** Frailty, Smartwatch, Machine Learning, XGBoost, Digital Health, Older Adults, Monitoring.



# Índice general

<b>1</b>	<b>INTRODUCCIÓN</b>	<b>1</b>
1.1	Fragilidad.....	1
1.1.1	Escalas de fragilidad .....	2
1.2	Fragilidad en personas mayores.....	6
1.2.1	Características principales .....	6
1.2.2	Causas de la fragilidad .....	8
1.2.3	Consecuencias de la fragilidad.....	8
1.3	Soluciones tecnológicas para la estimación de la fragilidad.....	9
<b>2</b>	<b>ESTADO DEL ARTE</b>	<b>10</b>
2.1	Síndrome de fragilidad y su evaluación.....	10
2.2	Funciones de los smartwatches para monitorear la salud en adultos mayores	11
2.3	Investigación actual sobre la estimación de la fragilidad con Smartwatches....	12
2.3.1	Proyectos pioneros en España .....	13
<b>3</b>	<b>OBJETIVO</b>	<b>15</b>
<b>4</b>	<b>METODOLOGÍA</b>	<b>16</b>
4.1	Parámetros de interés y recolección de datos .....	16
4.1.1	Actividad física.....	16
4.1.2	Calidad del sueño.....	17
4.1.3	Frecuencia cardíaca y su variabilidad (HRV).....	17
4.1.4	Temperatura de la piel.....	18

4.2	Modelo Machine Learning (ML) para la clasificación de Fragilidad .....	19
4.2.1	Modelo Extreme Gradient Boosting (XGBoost) .....	19
4.2.1.1	Qué es y cómo funciona el modelo XGBoost.....	20
4.2.1.2	Ventajas y desventajas .....	21
4.2.1.3	Aplicaciones .....	22

## 5 EXPERIMENTACIÓN 23

5.1	Adquisición de datos reales .....	24
5.1.1	Extracción de Actividad, Sueño y Recuperación .....	24
5.1.2	Extracción de Temperatura cutánea .....	25
5.2	Unificación y limpieza de datos.....	26
5.3	Generación de Datos Sintéticos .....	27
5.3.1	Justificación .....	27
5.3.2	Metodología de generación .....	27
5.3.3	Validación y Curación .....	28
5.4	Clasificación de la Fragilidad .....	28
5.4.1	Criterios de puntuación.....	28
5.4.1.1	Actividad física (Pasos activos) .....	28
5.4.1.2	Resiliencia fisiológica (HRV).....	29
5.4.1.3	Estrés fisiológico (Frecuencia Cardiaca Nocturna).....	29
5.4.1.4	Calidad del descanso (Puntuación del sueño) .....	29
5.4.2	Clasificación final .....	29
5.5	Modelo de Machine Learning (ML): XGBoost .....	30
5.5.1	Preparación del dataset .....	30
5.5.2	Entrenamiento y Evaluación.....	31
5.5.3	Creación y exportación del Pipeline final .....	32
5.6	Aplicación interactiva .....	33
5.7	Librerías utilizadas .....	36
5.7.1	Pandas.....	36

5.7.2	Request .....	36
5.7.3	PyYAML .....	36
5.7.4	Flask .....	36
5.7.5	Scikit-learn.....	37
5.7.6	Matplotlib.....	37
5.7.7	Seaborn .....	37
5.7.8	Imblearn .....	37
5.7.9	Xgboost .....	37
5.7.10	Streamlit.....	37
5.7.11	Joblib .....	37
5.7.12	Os.....	38
5.7.13	Argparse .....	38
5.7.14	Subprocess.....	38
5.8	Material utilizado .....	38
<b>6</b>	<b>RESULTADO</b>	<b>42</b>
<b>7</b>	<b>DISCUSIÓN</b>	<b>45</b>
<b>8</b>	<b>CONCLUSIÓN</b>	<b>47</b>
<b>9</b>	<b>TRABAJO FUTURO</b>	<b>49</b>
<b>10</b>	<b>BIBLIOGRAFÍA Y REFERENCIAS</b>	<b>50</b>
<b>11</b>	<b>ANEXOS</b>	<b>54</b>

## Índice de figuras

Figura 4.1.4-A. Mecanismos de envejecimiento. Estos mecanismos suelen aumentar la inflamación, lo que conduce al envejecimiento inflamatorio (Inflammaging).[27].....	19
Figura 4.2.1.1-A. El diagrama muestra el flujo general del algoritmo XGBoost. A partir del conjunto de datos de entrenamiento, el modelo crea una secuencia de árboles de decisión, donde cada árbol nuevo corrige los errores del anterior. Se optimiza una función de pérdida regularizada mediante el uso de gradientes y se actualizan las predicciones de forma iterativa hasta alcanzar una mejora mínima o el número máximo de iteraciones. Fuente: Elaboración propia basada en Chen & Guestrin.....	21
Figura 5-A. Flujo de trabajo completo del proyecto: desde la adquisición de datos hasta el modelado de la fragilidad y la interfaz de usuario con predicciones.....	23
Figura 5.6-A. Captura de pantalla de las instrucciones necesarias para utilizar la app interactiva para la predicción de la fragilidad.....	34
Figura 5.6-B. Captura de pantalla de la app interactiva para la predicción de la fragilidad con diferentes ficheros.....	35
Figura 5.6-C. Captura de pantalla de la app interactiva para la predicción de la fragilidad con un único fichero.....	35
Figura 5.8-A. Polar Vantage V3.....	40
Figura 6-A. Matriz de confusión del modelo XGBoost.....	37
Figura 6-B. Gráfico que representa la importancia de cada variable a la hora de estimar la fragilidad.....	38

## Índice de tablas

Tabla 1-A.....	3
Tabla 1-B.....	7
Tabla 6-A.....	42
Tabla 6-B.....	44



# 1 Introducción

El panorama demográfico global está cambiando notablemente, con un aumento continuo en la proporción de personas mayores dentro de la población global [6]. El envejecimiento de la población presenta desafíos significativos para la salud pública y los sistemas sanitarios, demandando un entendimiento detallado de las condiciones de salud que impactan especialmente a esta edad [6]. En este contexto, la fragilidad surge como un síndrome geriátrico de gran importancia, estrechamente relacionado con el proceso de envejecimiento [6]. Cada vez es más conocido como un factor decisivo que afecta a la vulnerabilidad de los adultos mayores, condicionando su capacidad de respuesta ante situaciones estresantes y anticipando con mayor exactitud resultados adversos en salud [6]. Por lo tanto, es fundamental comprender la fragilidad para que tanto profesionales de la salud como individuos, sean capaces de tomar acciones proactivas que ayuden a preservar y mejorar la salud y bienestar de las personas mayores [7]. La detección temprana y la gestión eficaz de la fragilidad está asociado a mejores resultados clínicos y a la prevención de daños innecesarios en esta población [8]. En definitiva, la fragilidad se caracteriza por una mayor vulnerabilidad y una disminución de la reserva fisiológica del organismo, términos importantes para comprender esta condición [6].

## 1.1 Fragilidad

En términos generales, la fragilidad se define como un estado de mayor vulnerabilidad que resulta de una disminución en la reserva y la función del cuerpo, un deterioro que se asocia típicamente al proceso de envejecimiento y que afecta múltiples sistemas fisiológicos [6].

Esta definición teórica destaca la naturaleza sistémica de la fragilidad, que va más allá del deterioro de un solo órgano o sistema. La fragilidad se define por tener una disminución

en la capacidad del organismo para mantener la homeostasis<sup>1</sup> y responder eficazmente a factores de estrés, ya sean cotidianos o agudos [6]. Incluso eventos menores, como una infección leve o un ajuste en la medicación, pueden provocar un impacto desproporcionado y significativo en la salud física y mental de una persona frágil [9]. La fragilidad puede compararse con la pérdida progresiva de las reservas naturales y la capacidad funcional del cuerpo con el tiempo [8]. Esta reducción deja a las personas más vulnerables, con menor capacidad para recuperarse de enfermedades o lesiones y más propensas a sufrir consecuencias negativas para la salud [9]. Es importante entender que la fragilidad no se limita a la debilidad física; es una condición médica compleja que implica una disminución en la capacidad del organismo para gestionar el estrés fisiológico, afectando también a la resistencia, la salud mental y la función cognitiva [10].

### **1.1.1 Escalas de fragilidad**

Aunque la definición teórica de fragilidad está globalmente aceptada, no existe una escala de fragilidad universalmente utilizada o aceptada para la clasificación de la fragilidad. Sin embargo, existen ciertas escalas de fragilidad válidas que consideran la naturaleza multidimensional de la fragilidad (validez aparente y de contenido) y han sido validadas para su evaluación, ya sea por la capacidad predictiva que obtienen de resultados de salud negativos relacionados con la fragilidad o por su validez concurrente con herramientas de fragilidad previamente validadas [6] (Tabla 1-A).

---

<sup>1</sup> Homeostasis: ‘Estado de equilibrio entre todos los sistemas del cuerpo necesarios para sobrevivir y funcionar de forma adecuada. Para mantener la homeostasis y responder a los cambios internos y externos, el cuerpo ajusta de manera constante los valores de ácido, presión arterial, azúcar en la sangre, electrolitos, energía, hormonas, oxígeno, proteínas y temperatura. De esta manera se logra mantener esos valores dentro de los límites normales. También se llama equilibrio homeostático y homeostasia.’. Diccionario de cáncer del NCI (Instituto Nacional del Cáncer). <https://www.cancer.gov/espanol/publicaciones/diccionarios/diccionario-cancer/def/homeostasis>

**Tabla 1-A.***Escalas de fragilidad válidas para la clasificación de la fragilidad [6].*

<b>Definición operativa</b>	<b>Número de ítems</b>	<b>Componentes</b>	<b>Criterios de clasificación</b>
Fried Frailty phenotype criteria	5	Pérdida de peso no intencionada, agotamiento, debilidad (fuerza de agarre), lentitud al caminar, baja actividad física.	0 = Robusto (no frágil)  1-2 = Prefrágil  $\geq 3$ = Frágil
Frailty Index (déficits acumulados)	~30-70	Acumulación de déficits de salud (síntomas, signos, discapacidades, mediciones de laboratorio).	Variable continua; un valor $> 0.25$ = Frágil
Edmonton Frailty Scale (EFS)	11	Cognición, hospitalización, salud general, capacidad funcional, soporte social, uso de medicamentos, nutrición, estado de ánimo, continencia	0-5 = No frágil 6-7 = Vulnerable 8-9 = Fragilidad leve 10-11 = Fragilidad moderada 12-17 = Fragilidad severa
Clinical Frailty Scale (CFS)	1	Evaluación visual y escrita de la fragilidad en una escala de 1 (muy en forma) a 9 (terminalmente enfermo)	1-3 = No frágil 4 = Vulnerable 5-9 = Frágil
FRAIL Scale	5	Fatiga, resistencia (capacidad para subir escaleras), ambulación (capacidad para caminar una cuadra), enfermedades, pérdida de peso)	0 = Robusto 1-2 = Pre-frágil $\geq 3$ = Frágil
Tilburg Frailty Indicator	15	Dominios físicos (8 ítems), psicológico (5 ítems) y social (3 ítems)	Puntuación $\geq 5$ = Fragilidad

Groningen Frailty Indicator	15	Dominios físicos, cognitivo, social y psicológico	$\geq 4$ = Fragilidad
Modified Frailty Index (mFI)	11	Estado funcional, diabetes mellitus, problemas pulmonares, insuficiencia cardíaca congestiva, infarto de miocardio, problemas cardíacos, hipertensión, sensorio alterado, accidente isquémico transitorio previo, historia de accidente cerebrovascular, enfermedad vascular periférica	0 = Robusto 0 a $< 0.21$ = Pre-frágil $\geq 0.21$ = Fragilidad
Study of Osteoporotic Fractures (SOF) Index	3	Pérdida de peso, agotamiento, levantarse de una silla	0 = Robusto 1-2 = Pre-frágil $\geq 2$ = Frágil
Multidimensional Prognostic Index (MPI)	8	Comorbilidad, nutrición, polifarmacia, riesgo de úlceras por presión, estado de vida, actividades de la vida diaria, actividades instrumentales de la vida diaria	$< 0.34$ = Robusto 0.34 – 0.66 = Pre-frágil $\geq 0.66$ = Frágil
Trauma-Specific Frailty Index	15	Comorbilidad (x3), actividades diarias (x5), actitud de salud (x5), nutrición (x1)	$\geq 0.25$ = Frágil
Rockwood frailty assessment	4	Actividades de la vida diaria, función de la vejiga, función intestinal, cognición	$\geq 2$ = Frágil
Kihon Checklist	25	Fuerza física, nutrición, función oral, socialización, memoria, estado de ánimo, estilo de vida	Puntuación dicotómica de todos los ítems según el índice de fragilidad.

			Un valor de corte > 0.25 = Fragilidad
Preoperative Frailty Index (pFI)	30	Déficits de salud acumulativos: 0 = ausencia de todos los déficits- 1 = presencia de todos los déficits	>0.25 = Frágil
Comprehensive Assessment of Frailty (CAF)	14	4 dominios: Evaluación de laboratorio, Evaluación del fenotipo, Evaluación del rendimiento físico modificado y Evaluación CSHA CFS	1-10 = No frágil 11-25 = Moderadamente frágil 26-35 = Gravemente frágil
Frailty predicts death One year after CARDiac Surgery Test (FORECAST)	5	Levantarse de una silla, debilidad, subir escaleras, evaluación de la escala de fragilidad clínica CSHA, creatinina sérica	0-4 = No frágil 5-7 = Moderadamente frágil 8-14 = Gravemente frágil
Robinson criteria	7	Tiempo para levantarse y empezar, índice de Katz de actividades de la vida diaria, cognición, índice de Charleston, anemia, nutrición, caídas	0-1 = No frágil 2-3 = Pre-frágil 4-7 = Frágil
National Surgical Quality Improvement Program Frailty Index (NSQIP-FI)	11	Antecedentes de: <b>Enfermedades crónicas:</b> Diabetes, EPOC, neumonía, insuficiencia cardíaca cognitiva, infarto de miocardio reciente (dentro de 6 meses post-cirugía), angina, enfermedad vascular periférica o dolor en reposo. <b>Eventos cardiovasculares:</b> Intervención coronaria percutánea, cirugía cardíaca, accidente isquémico transitorio, accidente	>0.25 = Frágil

---

cardiovascular con disfunción residual.

**Estado funcional:** Deterioro funcional, deterioro del sensorio.

**Medicación:** Uso de antihipertensivos.

## **1.2 Fragilidad en personas mayores**

En el contexto de los adultos mayores, la fragilidad se define como un estado de mayor vulnerabilidad derivado de la disminución progresiva de las reservas fisiológicas del cuerpo con el envejecimiento [11]. Se caracteriza por déficits asociados a la edad en el funcionamiento normal de diversos sistemas corporales, lo que reduce la capacidad de enfrentar factores de estrés diarios o agudos [7]. Esta mayor vulnerabilidad en adultos mayores implica un riesgo significativamente elevado de experimentar resultados adversos para la salud, como caídas, desarrollo de discapacidades, necesidad de hospitalización y un aumento en la mortalidad [6]. Es importante distinguir entre fragilidad y envejecimiento normal [6], ya que el envejecimiento es un factor de riesgo clave para la fragilidad que no todos los adultos mayores la desarrollan, mientras que la fragilidad implica un deterioro funcional que va más allá de los cambios fisiológicos típicos del envejecimiento [9]. Por ende, no debe considerarse una consecuencia inevitable del envejecimiento, sino un síndrome geriátrico específico con importantes implicaciones clínicas [9].

### **1.2.1 Características principales**

La fragilidad en los adultos mayores se refleja en diversos signos y síntomas característicos que usualmente se evalúan utilizando modelos como los descritos en el apartado 1.1.1, aunque los más utilizados son el fenotipo de fragilidad de Freid y el Índice de Fragilidad (IF) [6].

El fenotipo de fragilidad de Freid propone que la fragilidad se defina como un síndrome clínico en el que están presente tres o más de los cinco criterios siguientes: pérdida de peso no intencional ( $\geq 4.5$  kilos en el último año), agotamiento auto informado, debilidad (fuerza

de agarre), velocidad de marcha lenta y baja actividad física (kcal activas gastadas por semana) [6] (Tabla 1-B).

**Tabla 1-B**

*Componentes de la definición operativa del fenotipo de fragilidad de Fried para la clasificación de la fragilidad [6]*

<b>Criterio</b>	<b>Método de evaluación</b>
<b>1. Pérdida de peso involuntaria</b>	Pérdida de peso no intencional auto informada de $\geq 4.5$ kilos en el último año
<b>2. Agotamiento auto informado</b>	Escala de depresión del Centro de Estudios Epidemiológicos: dos preguntas subjetivas sobre resistencia y energía, con una puntuación de 0 a 2 (una puntuación $> 1$ en cualquiera de estas preguntas significa la confirmación de los criterios de agotamiento)
<b>3. Debilidad</b>	Medición de la fuerza de agarre. Criterios de clasificación según el sexo y el índice de masa corporal
<b>4. Velocidad de marcha lenta</b>	Evaluación de la marca a 4.5 metros. Criterios de clasificación según sexo y altura
<b>5. Baja actividad física</b>	Versión abreviada del Cuestionarios de Actividades de Ocio de Minnesota, utilizado para estimar el gasto calórico activo semanal. Criterios de clasificación según el sexo.

Por otra parte, la IF plantea que la fragilidad utilice un modelo matemático que evalúa según la acumulación de déficits, dichos déficits incluyen cualquier síntoma, signo, discapacidad o resultado de laboratorio considerado anormal [6]. La puntuación del IF se calcula como la proporción de estos déficits potenciales presentes, que por lo general, comprende entre 30 y 70 elementos relacionados con diversos aspectos de salud y el bienestar.

### **1.2.2 Causas de la fragilidad**

La fragilidad en la vejez es una condición compleja creada por diversos factores, resultado de la interacción entre cambios fisiológicos propios del envejecimiento, enfermedades crónicas, factores de estilo de vida y determinantes sociales. Entre los cambios fisiológicos destaca la sarcopenia, que es la pérdida progresiva de masa y fuerza muscular, elemento clave en la expresión física de la fragilidad [6].

Dicha reducción muscular está relacionada con alteraciones anatómicas y bioquímicas producidas en el músculo envejecido [12]. Del mismo modo, la inflamación crónica y la activación del sistema inmunitario está altamente correlacionado con el desarrollo de la fragilidad, ya que afecta a la función muscular, que produce anemia y disminuye la capacidad cardíaca. Además, la desregulación hormonal, como el aumento de cortisol, la reducción de estrógeno y testosterona, y la deficiencia de vitamina D, también está implicada en su desarrollo [13].

La presencia de enfermedades crónicas, como cardiovasculares, diabetes, artritis, EPOC o demencia, aumenta el riesgo de fragilidad. Además, hay factores que agravan la aparición y progresión de la fragilidad: el estilo de vida, la inactividad física, la nutrición deficiente y el tabaquismo [6].

Por otro lado, determinantes sociales como el aislamiento, el bajo nivel socioeconómico y la falta de apoyo social incrementan la vulnerabilidad a la fragilidad en adultos mayores. Y algo común en ese grupo de personas, la polifarmacia, o uso de múltiples medicamentos, puede aumentar el riesgo debido a efectos secundarios o interacciones entre los mismos medicamentos [6].

### **1.2.3 Consecuencias de la fragilidad**

La fragilidad en adultos mayores está relacionada con diversos resultados adversos que impactan gravemente a su salud, bienestar y que generan una gran carga en los sistemas de salud. Lo más destacado es el alto riesgo para sufrir caídas y fracturas, que termina en lesiones severas e inclusive, la discapacidad, que dificulta sus actividades cotidianas y compromete su independencia [6].

Los adultos mayores frágiles son más propensos a las hospitalizaciones con largas estancias que tensan los recursos sanitarios, además de tener más complicaciones posquirúrgicas, infecciones y una lenta recuperación debido a su menor reserva fisiológica.



Aunque la consecuencia más importante es el incremento del riesgo de mortalidad, lo que hace resaltar la gravedad de este síndrome [13].

En definitiva, la fragilidad reduce la calidad de vida y aumenta los costos sanitarios por el mayor uso de recursos médicos.

## 1.3 Soluciones tecnológicas para la estimación de la fragilidad

Como se ha mencionado anteriormente (Escala de fragilidad), las escalas clínicas y pruebas físicas son limitadas ya que deben ser presenciales, consumiendo así recursos, y la inexistencia de un monitoreo continuo. Por ello, se proponen soluciones tecnológicas que pretenden superar estas limitaciones:

- **Sensores vestibles:** Monitorean la actividad física, velocidad de la marcha, frecuencia cardíaca, sueño y caídas (ej. Relojes inteligentes, ropa con sensores)[14].
- **Dispositivos IoT (Internet of Things):** Sensores de presencia, puertas y básculas que monitorean rutinas, actividad y peso en el hogar (ej. Proyecto AI3CORD [15]).
- **Aplicaciones móviles:** Cuestionarios (ej. FRail), integración con wearables, herramientas clínicas (ej. PowerFrail [16]).
- **Cámaras 3D:** Son capaces de evaluar la marcha y el equilibrio objetivamente (ej. Cátedra cuatrocuenta-Kineactiv [17]).
- **Inteligencia artificial (IA):** Analiza datos de wearables/IoT para detectar y predecir la fragilidad. Lo utilizan en el Proyecto IA3cord [15] y FRELSA [18].

Estas soluciones se integran en atención primaria, telemedicina e investigación geriátrica lo que permite un monitoreo remoto y estudios mas longitudinales. Además de complementar la VGI<sup>2</sup> (Valoración Geriátrica Integral) ya que ofrecen datos continuos y objetivos.

---

<sup>2</sup> “La Valoración Geriátrica integral (VGI) es un proceso diagnóstico multidimensional, generalmente interdisciplinario, dirigido a cuantificar los problemas y las capacidades médicas, funcionales, psíquicas y sociales de una persona mayor para trazar un plan de tratamiento y seguimiento. Su realización requiere tiempo y entrenamiento especializado.” Sánchez-García E. Actualización en valoración geriátrica integral. ANALES RANM [Internet]. Real Academia Nacional de Medicina de España; An RANM · Año 2020 · numero 137(01):77-82. DOI: <http://dx.doi.org/10.32440/ar.2020.137.01.doc01>

## **2 Estado del arte**

### **2.1 Síndrome de fragilidad y su evaluación**

El envejecimiento de la población a nivel mundial constituye una tendencia demográfica significativa, especialmente en España, donde hay un porcentaje elevado de población que supera los 65 años [19]. Debido a este cambio demográfico es importante abordar las condiciones de salud relacionadas con la edad, como la fragilidad. Como ya se mencionó, la fragilidad se define como un deterioro relacionado con la edad en las reservas fisiológicas, lo que lleva a una mayor vulnerabilidad a los factores de estrés y a resultados adversos para la salud, como discapacidad, hospitalización, caídas y mortalidad (Fragilidad en personas mayores). Sin embargo, la fragilidad se distingue de la comorbilidad, la discapacidad y la dependencia, aunque puede coexistir con ellas y aumentar el riesgo de estas condiciones. Por ello, es importante reconocer la fragilidad, ya que es un indicador y factor de riesgo de discapacidad y eventos adversos graves [19]. Con el aumento de la fragilidad en una sociedad que envejece, sobre todo en España, es clave buscar formas nuevas y prácticas para detectarla y tratarla a tiempo.

Tal como se explicó antes, los métodos tradicionales para evaluar la fragilidad, como el fenotipo de Freid, la escala de FRAIL o la Valoración Geriátrica Integral (VGI), son útiles, pero suelen requerir clínicas, equipos especializados o mucho tiempo. Esto los hace poco prácticos para un monitoreo continuo en adultos mayores que viven en sus hogares. Por eso, los smartwatches como herramientas accesibles y fáciles de usar, podrían ser una gran solución para detectar la fragilidad a tiempo.

Las tecnologías vestibles, específicamente los smartwatches, han aumentado su popularidad para la estimación de la fragilidad, ya que son cada vez más frecuentes y ofrecen un monitoreo continuo y en tiempo real de diversos parámetros relacionados con la salud. Puede recopilar datos de forma pasiva sobre la actividad física, los patrones de sueño, la frecuencia cardíaca y, potencialmente, la velocidad y el equilibrio de la marcha, que son

importantes para los criterios de fragilidad. Los smartwatches ofrecen una manera más cómoda y menos invasiva de monitorear los indicadores de fragilidad en comparación con los métodos clínicos tradicionales [20]. Gracias a su capacidad para monitorear de forma continua, podrían captar pequeños cambios en el estado de fragilidad con el tiempo, lo que facilitaría intervenciones más rápidas y una mejor comprensión de cómo evoluciona este síndrome.

## **2.2 Funciones de los smartwatches para monitorear la salud en adultos mayores**

Los smartwatches ofrecen diversas funciones relevantes para la evaluación de la fragilidad en adultos mayores, entre las que destacan [20]:

- **Seguimiento de la actividad física:** Capacidad fundamental, ya que pueden monitorear los pasos dados, la distancia recorrida, los tipos de actividad y la duración de la actividad, siendo relevantes para el criterio de baja actividad física de la fragilidad.
- **Monitoreo continuo de la frecuencia cardíaca:** Proporciona información sobre la salud cardiovascular y ayuda a identificar posibles anomalías relacionadas con la fragilidad.
- **Análisis del sueño:** Función relevante, ya que los smartwatches pueden rastrear la duración del sueño, las etapas del sueño (ligero, profundo, REM) y la calidad del sueño, lo que puede reflejar la salud y el bienestar general, aspectos que podrían estar relacionados con la fragilidad.

Además de estas funciones, algunos smartwatches tienen características integradas de detección de caídas que alertan automáticamente a los cuidadores o servicios de emergencia en caso de una caída, un factor de riesgo bastante importante para los adultos mayores frágiles. Por otra parte, los smartwatches cuentan con acelerómetros y giroscopios que son importantes para analizar parámetros de la marcha como la velocidad y la estabilidad, indicadores cruciales de fragilidad. Hay smartwatches avanzados capaces de medir la saturación de oxígeno en sangre (SpO2) e incluso realizar electrocardiogramas (ECG), proporcionando información cardiovascular más detallada. Gracias a los sensores avanzados de los smartwatches modernos generan una amplia gama de datos se pueden relacionar con

criterios de evaluaciones tradicionales de fragilidad, permitiendo una estimación completa al combinar múltiples parámetros.

A pesar de todas estas cualidades hay que tener en cuenta la precisión y validez de los datos de salud recopilados por los smartwatches en comparación con los métodos tradicionales.

En un estudio realizado recientemente por un equipo de investigadores liderado por Cailbhe Doherty, profesor de la Universidad de Dublín, se hizo una revisión que evaluó la precisión de los smartwatches llegando a la conclusión de que la precisión es muy cambiante, con variaciones dependiendo del parámetro de salud medido, aunque la investigación se va actualizando continuamente a medida que los dispositivos van mejorando. Uno de los aspectos positivos del estudio fue la precisión de los smartwatches en la medición de la frecuencia y la detección de arritmias. Sin embargo, datos como la capacidad aeróbica (VO2max), actividad física y conteo de pasos y monitoreo del sueño, son imprecisos en los smartwatches ya que tienden a sobreestimar los datos. La precisión puede diferir entre marcas y modelos debido a los diferentes algoritmos y metodologías utilizadas por cada smartwatch [21].

Por otra parte, hay que considerar la usabilidad y la aceptación de los smartwatches por parte de la población adulta mayor. La facilidad de uso, las interfaces intuitivas y los tamaños de fuente grandes son factores importantes para los adultos mayores y que ayudarían a una implementación exitosa. Además, funciones como recordatorios de medicinas, botones de emergencia y asistentes de voz pueden mejorar la usabilidad y ser un plus en la seguridad [22]. Otro aspecto importante es la duración de la batería, ya que la carga frecuente puede ser un obstáculo para algunos adultos mayores. Por ello, el éxito de usar smartwatches para estimar la fragilidad en adultos mayores depende de considerar lo que ellos necesitan y prefieren, como que sean fáciles de usar, cómodos y que les parezca útiles.

## **2.3 Investigación actual sobre la estimación de la fragilidad con Smartwatches**

En España, donde la población envejece rápidamente, la fragilidad es un tema clave, y los métodos tradicionales como los criterios de Freid o la escala FRAIL, aunque útiles, suelen requerir entornos clínicos. Por eso, los smartwatches están ganando terreno como una

herramienta práctica para monitorear la salud de los adultos mayores de forma menos invasiva y más accesible.

### 2.3.1 Proyectos pioneros en España

Existen varios estudios en España que están explorando cómo los smartwatches pueden ayudar a detectar y monitorear la fragilidad. Algunos de ellos son:

- **Proyecto AI3cord** [15]: Proyecto desarrollado por el Instituto de Biomecánica (IBV), mediante el programa de Proyectos Estratégicos en Cooperación de la Agència Valenciana de la Innovació (AVI), que ha permitido generar una plataforma tecnológica que, a través del uso de dispositivos IoT y técnicas de análisis de datos basadas en IA, es capaz de evaluar de forma remota, dinámica y mínimamente intrusiva, nuevos indicadores orientados al seguimiento y prevención de la fragilidad en personas mayores.

Los dispositivos IoT utilizados en la plataforma AI3cord son:

- **Reloj inteligente:** mide frecuencia cardíaca, velocidad de la marcha, número de pasos, calorías consumidas y distancia recorrida.
- **Aplicación móvil:** registra mediante cuestionarios periódicos percepción de soledad, fatiga, calidad del descanso o memoria entre otros.
- **Sensores de presencia:** detectar la actividad en el hogar, evaluando actividad física y patrones de comportamiento.
- **Sensor de puerta:** permite entradas/salidas del domicilio, evaluando tiempo en casa, fuera o acompañado.
- **Báscula digital:** controla el peso regularmente.

En cuanto al uso del smartwatch, su objetivo fue la detección de patrones anómalos en las señales proporcionadas por el smartwatch usando combinaciones de técnicas estadísticas o redes neuronales. Esta aplicación permitió detectar cambios significativos en los cambios registrado por el smartwatch que se asociaron a eventos clínicos registrados durante el estudio como problemas de salud físicas, procedimientos médicos o empeoramientos del estado de salud mental de los participantes [15].

- **Proyecto Senior Monitoring (Castelló)** [23]: Desarrollado por la Cátedra Cuatroochenta de Inteligencia Artificial, Salud y Bienestar de la Universitat Jaume I, es un sistema de localización en interiores basado en tecnología Bluetooth Low Energy (BLE), diseñado para personas mayores. Funciona mediante balizas bluetooth instaladas en diferentes habitaciones, permitiendo conocer su ubicación dentro del hogar.

Los dispositivos recopilan datos en tiempo real, los cuales se utilizan para crear modelos de comportamiento mediante inteligencia artificial. Estos modelos permiten identificar patrones habituales y detectar posibles anomalías, que podrían estar relacionadas con un deterioro cognitivo temprano, información útil para investigadores en salud física y mental [23].

### 3 Objetivo

El objetivo principal de este Trabajo de Fin de Grado (TFG) es desarrollar y validar una metodología para estimar la fragilidad en personas mayores utilizando datos recopilados a través de un smartwatch de uso comercial. Los objetivos planteados para lograr el objetivo general son:

- **Identificar y seleccionar los parámetros relevantes** de los datos proporcionados por el smartwatch (por ejemplo, patrones de actividad física, frecuencia cardíaca, calidad de sueño) que puedan estar correlacionados con los indicadores de fragilidad.
- **Diseñar un algoritmo o modelo predictivo** capaz de integrar los datos del smartwatch y transformarlos en una estimación de fragilidad, utilizando métodos de aprendizaje automático o estadísticos adecuados.
- **Evaluar la precisión y fiabilidad** del modelo propuesto.

## 4 Metodología

El trabajo se estructura en dos pilares fundamentales: primero, la identificación y recolección de parámetros fisiológicos y de comportamiento relevantes proporcionados por el smartwatch; y segundo, la aplicación de técnicas de Machine Learning (ML) para analizar dichos parámetros y construir un modelo predictivo capaz de clasificar el nivel de fragilidad de un individuo (ej. Robusto, pre-frágil, frágil).

### 4.1 Parámetros de interés y recolección de datos

La selección de variables es un paso clave, ya que deben basarse en la evidencia fisiológica del síndrome de la fragilidad. Los smartwatches modernos cuentan con sensores que facilitan el monitoreo pasivo y continuo de los siguientes parámetros:

#### 4.1.1 Actividad física

La reducción de la actividad físicas es uno de los factores centrales del fenotipo de la fragilidad (Criterios de Fried).

- **Métricas clave:**
  - **Número de pasos diarios:** Indicador general del nivel de actividad y movimiento. Este dato se ha utilizado en modelos predictivos y se ha demostrado que el número de pasos tiene una gran relación con la progresión de la fragilidad [24].
  - **Minutos de actividad (Intensidad ligera, moderada y vigorosa):** Permite diferenciar entre el tiempo dedicado a un comportamiento sedentario, actividad física ligera (LPA, por sus siglas en inglés) y actividad física de moderada a vigorosa (MVPA). Por ello, un mayor número de minutos sedentarios y menos minutos activos, se asocian a una mayor probabilidad de ser frágil [25].



- **Periodos de inactividad prolongada:** Detectar estos periodos de inactividad puede ser un marcador de sedentarismo extremo o de recuperación lenta.
- **Cadencia (Pasos por Minuto):** La lentitud al caminar es un criterio de diagnóstico del fenotipo de Fried.
- **Relevancia para la Fragilidad:** Una baja cantidad de pasos y la ausencia de actividad de intensidad moderada están directamente relacionadas con la sarcopenia, la dinapenia (pérdida de fuerza) y el agotamiento energético, siendo estos pilares de la fragilidad.

#### 4.1.2 Calidad del sueño

En la población mayor, las alteraciones del sueño son comunes y se han asociado con un mayor riesgo de fragilidad, deterioro cognitivo y un peor estado de salud general.

- **Métricas clave:**
  - **Duración total del sueño:** Horas y minutos dormidos por la noche.
  - **Fases del sueño (Ligero, Profundo, REM, Rapid Eye Movement):** La arquitectura del sueño es fundamental, ya que una reducción del sueño profundo y REM se asocia a una peor recuperación física y consolidación de la memoria.
  - **Número de despertares:** La fragmentación del sueño es un indicador de su baja calidad.
  - **Eficiencia del sueño:** Proporción de tiempo en cama dedicado a dormir. La baja eficiencia de sueño indica un sueño fragmentado o de mala calidad.
- **Relevancia de la Fragilidad:** Un sueño no reparador afecta a la recuperación muscular, la función hormonal (ej. Cortisol) y la función cognitiva, agravando el estado de vulnerabilidad.

#### 4.1.3 Frecuencia cardíaca y su variabilidad (HRV)

La frecuencia cardíaca (FC) y la variabilidad de la frecuencia cardíaca (HRV) son indicadores importantes de la función del sistema nervioso autónomo (SNA), jugando un papel importante en la regulación homeostática del organismo. La disfunción del SNA está relacionado con el proceso de envejecimiento y con el síndrome de fragilidad.[26]

- **Métricas clave:**
  - **Frecuencia cardíaca en reposo (RHR, Rest Heart Rate):** Una RHR alta puede indicar un peor estado de forma cardiovascular o la presencia de estrés fisiológico crónico.
  - **Variabilidad de la Frecuencia Cardíaca (HRV):** Mide la variación en el tiempo entre latidos consecutivos. Es un potente indicador de la función del sistema nervioso autónomo y de la capacidad del cuerpo para adaptarse al estrés. Una HRV baja se asocia con una peor salud y un mayor riesgo de eventos adversos.
- **Relevancia para la Fragilidad:** Como ya se ha comentado, la fragilidad implica una desregulación de múltiples sistemas fisiológicos, siendo la HRV un ‘meta-parámetro’ que captura esta desregulación. Una HRV crónicamente baja refleja una resiliencia fisiológica reducida, que en esencia es la fragilidad.

#### **4.1.4 Temperatura de la piel**

A pesar de ser una métrica más indirecta, puede aportar información valiosa sobre los ritmos circadianos y los procesos inflamatorios.

- **Métricas clave:**
  - **Temperatura nocturna de la piel:** Las variaciones de temperatura durante la noche pueden reflejar la calidad del sueño y la regulación térmica del cuerpo.
  - **Anomalías en la temperatura:** Picos o descensos inesperados podrían indicar una respuesta inflamatoria (ej. Infección subclínica), un factor estresante conocido que puede provocar una transición hacia un estado más frágil.
- **Relevancia para la fragilidad:** La inflamación crónica de bajo grado (“inflammaging”) es un mecanismo subyacente de la fragilidad. La temperatura corporal puede servir como un indicador para detectar estos estados.




Figura 4.1.4 -A. Mecanismos de envejecimiento. Estos mecanismos suelen aumentar la inflamación, lo que conduce al envejecimiento inflamatorio (Inflammaging).[27]

## 4.2 Modelo Machine Learning (ML) para la clasificación de Fragilidad

El Machine Learning (ML) proporciona un conjunto de herramientas computacionales potentes para analizar los datos generados por los smartwatches, los cuales son complejos y multidimensionales [28]. Dado que la fragilidad es un síndrome multifactorial, influenciado por la interacción entre factores biológicos, psicológicos y sociales, que varía entre individuos, los modelos de ML se ajustan a este tipo de problemas ya que pueden identificar patrones complejos, no lineales y relaciones ocultas entre grandes conjuntos de datos que podrían no ser evidentes mediante análisis estadísticos tradicionales [28]. Al combinar datos de diversos parámetros obtenidos de los smartwatches, los modelos ML pueden estimar, clasificar o predecir el estado de fragilidad de una persona y su riesgo de desarrollarla.

### 4.2.1 Modelo Extreme Gradient Boosting (XGBoost)

Para este Trabajo de Fin de Grado (TFG), que pretende estimar la fragilidad en personas mayores mediante datos de smartwatches, se debe seleccionar un modelo de Machine Learning que ofrezca un equilibrio entre precisión predictiva, interpretabilidad, viabilidad de implementación y eficiencia en el uso de recursos. En este sentido, el modelo XGBoost

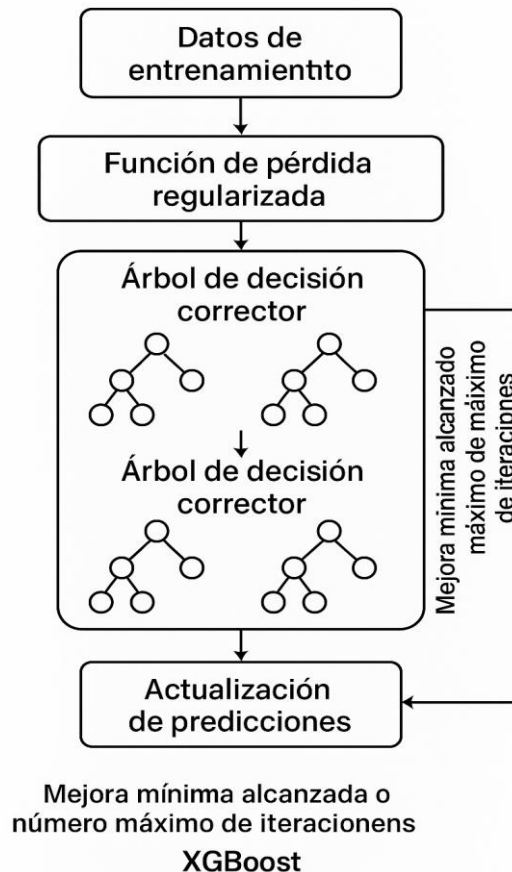
(Extreme Gradient Boosting) se posiciona como una alternativa altamente competitiva frente a otros algoritmos como Random Forest, gracias a su rendimiento sobresaliente y capacidad de generalización.

#### **4.2.1.1 Qué es y cómo funciona el modelo XGBoost**

XGBoost es un algoritmo de aprendizaje automático basado en árboles de decisión y optimización por gradiente, diseñado específicamente para maximizar la eficiencia y precisión en tareas tanto de clasificación como de regresión. Fue desarrollado por Tianqi Chen y Carlos Guestrin como una mejora del algoritmo tradicional de Gradient Boosting, centrándose en la velocidad de ejecución, la regularización y la capacidad de manejar grandes volúmenes de datos [29].

El funcionamiento de XGBoost se basa en la construcción secuencial de árboles, donde cada nuevo árbol se entrena para corregir los errores cometidos por los árboles anteriores. Para ello, el modelo minimiza una función de pérdida mediante el cálculo del gradiente (derivada) respecto a las predicciones previas. A diferencia de otros métodos, XGBoost incorpora términos de regularización que penalizan la complejidad del modelo, ayudando a evitar el sobreajuste [29].

Además, XGBoost emplea técnicas de paralelización, poda temprana (early stopping) y manejo eficiente de valores faltantes, lo que lo convierte en uno de los algoritmos más rápidos y precisos disponibles actualmente en el campo del aprendizaje supervisado [29].



**Figura 4.2.1.1-A.** El diagrama muestra el flujo general del algoritmo XGBoost. A partir del conjunto de datos de entrenamiento, el modelo crea una secuencia de árboles de decisión, donde cada árbol nuevo corrige los errores del anterior. Se optimiza una función de pérdida regularizada mediante el uso de gradientes y se actualizan las predicciones de forma iterativa hasta alcanzar una mejora mínima o el número máximo de iteraciones. Fuente: Elaboración propia basada en Chen & Guestrin.

#### 4.2.1.2 Ventajas y desventajas

Sus principales ventajas son:

- Alto rendimiento predictivo, superior al de muchos modelos tradicionales.
- Regularización integrada (L1 y L2), que mejora la capacidad de generalización.
- Optimización computacional mediante paralelización y gestión eficiente de recursos.
- Soporte nativo para valores faltantes, que permite trabajar con datos incompletos.
- Importancia de variables fácilmente interpretable a través de métricas como gain, cover o weight.

En cuanto a sus desventajas:

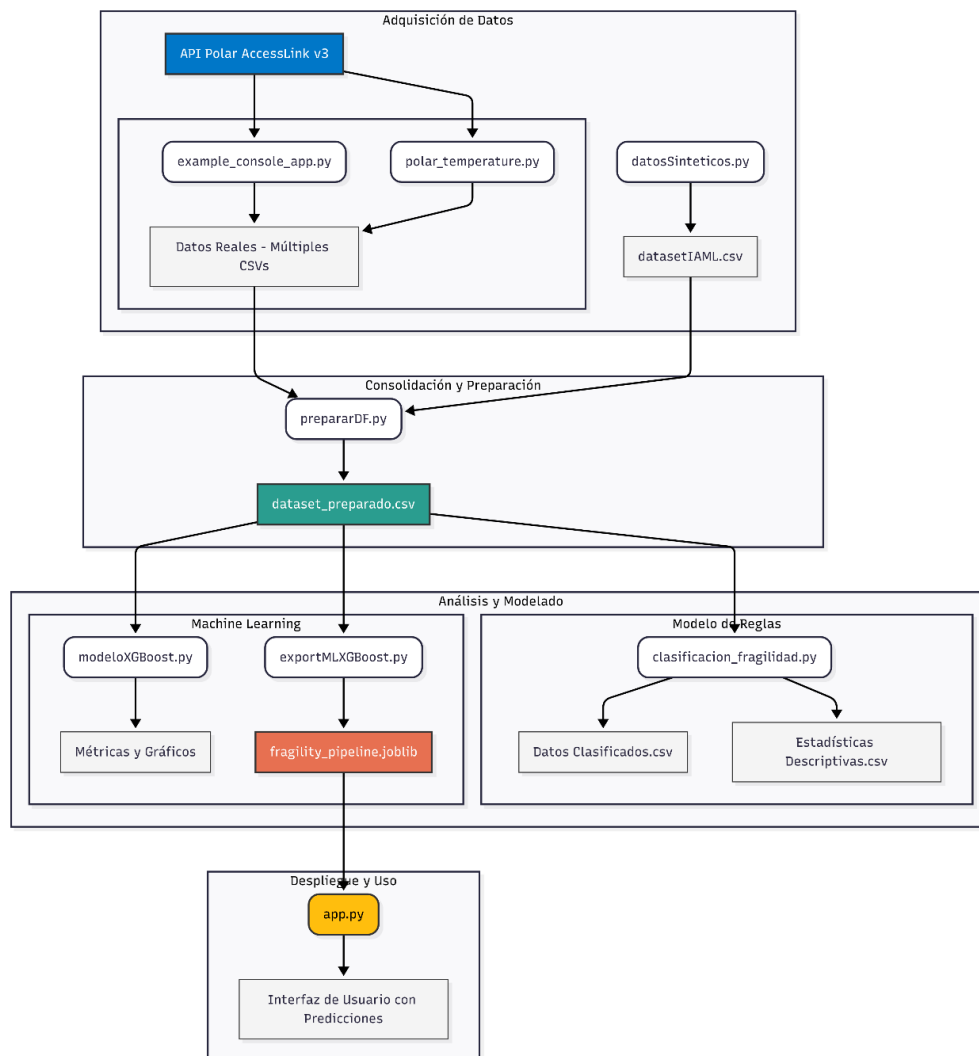
- Complejidad algorítmica mayor que modelos simples, lo que puede dificultar su interpretación.
- Mayor necesidad de ajuste de hiperparámetros, lo que puede requerir más tiempo de desarrollo.
- Sensibilidad al ruido en conjuntos de datos muy pequeños o desbalanceados si no se ajusta correctamente.

#### **4.2.1.3 Aplicaciones**

XGBoost se ha consolidado como uno de los algoritmos más utilizados en competiciones de ciencia de datos y en aplicaciones reales, especialmente en campos como la medicina (predicción de enfermedades crónicas), bioinformática (análisis de expresiones génicas), finanzas (detección de fraude), y salud pública (predicción de riesgos), gracias a su capacidad para modelar relaciones complejas de forma eficiente y precisa.

## 5 Experimentación

En este apartado se detalla el diseño experimental llevado a cabo para explorar la viabilidad de estimar la fragilidad en personas mayores a través de los datos recopilados por smartwatches. A continuación, se muestra una imagen del flujo de trabajo. Todo el código desarrollado se encuentra en el **ANEXO A**.



**Figura 5-A. Flujo de trabajo completo del proyecto: desde la adquisición de datos hasta el modelado de la fragilidad y la interfaz de usuario con predicciones.**

## 5.1 Adquisición de datos reales

Se utilizó dos smartwatches de la marca **Polar Vantage V3**, los cuales cuentan con una API que permite obtener los datos en bruto recopilados. Específicamente, se realizó mediante la [API Polar AccessLink v3](#), interfaz que permite el acceso a datos de dispositivos Polar [30]. El acceso a esta API no es público y requiere de un proceso de registro y autorización previo, que es de suma importancia para la recolección de datos:

1. **Registro de la aplicación:** En primer lugar, es necesario registrar una aplicación “cliente” en la plataforma para desarrolladores Polar Open AccessLink. Este proceso proporciona unas credenciales únicas (`client_id` y `client_secret`) que identifican el proyecto de investigación.
2. **Autorización del usuario:** Posteriormente, el usuario debe tener una cuenta en Polar Flow para poder obtener su información. Este debe autorizar explícitamente a la aplicación cliente para que acceda a sus datos, mediante un flujo de autorización estándar OAuth 2.0, tras el cual la API concede un token de acceso (`access_token`) específico para ese usuario.

Una vez obtenidas estas credenciales y tokens, se almacenan en un fichero de configuración (`config.yml`) y dado que los datos de interés se encontraban en diferentes *endpoints* de la PAI, se utilizaron dos scripts especializados para su extracción.

### 5.1.1 Extracción de Actividad, Sueño y Recuperación

Para los datos de actividad diaria, sueño y recuperación nocturna (*recharge*), se adaptó una aplicación de consola en Python (`example_console_app.py`). Los cambios realizados se centraron en implementar un sistema robusto de persistencia de datos para procesar respuesta JSON de la API y almacenarlas de forma estructurada en ficheros CSV (`polar_daily_activities.csv`, `polar_sleep_summary.csv`, etc.). Para evitar la duplicación de registros, el script primero verifica las fechas ya guardadas en los ficheros y solo añade los días que no existe. El siguiente fragmento de `example_console_app.py` muestra esta lógica para los datos del sueño:



```

# Leer fechas existentes si el archivo ya existe
existing_dates = set()
file_exists = os.path.exists(csv_filename)

if file_exists:
with open(csv_filename, mode='r', encoding='utf-8') as csv_file:
    reader = csv.DictReader(csv_file)
    existing_dates = {row['date'] for row in reader}

# Dentro del bucle que procesa los datos de la API:
for night in sleep_data['nights']:
    night_date = night.get('date', '')
    if not night_date or night_date in existing_dates:
        continue # Se salta la noche si la fecha ya existe

```

Dada que la obtención de la actividad diaria puede sincronizar múltiples resúmenes para una misma fecha, se refinó la lógica del script para seleccionar únicamente el registro con el valor máximo de pasos activos (active-steps) de cada día.

```

# Agrupar datos de la API por día y quedarse con el máximo 'active-
steps'
api_daily_max = {}
for url in resource_urls:
    summary = transaction.get_activity_summary(url)
    date = summary.get('date')
    if not date:
        continue

    current_steps = summary.get('active-steps', 0) or 0

    # Si la fecha no está registrada o los pasos del registro actual
    son mayores, se guarda
    if date not in api_daily_max or current_steps >
    api_daily_max[date].get('active-steps', 0):
        api_daily_max[date] = summary

```

### 5.1.2 Extracción de Temperatura cutánea

Para la obtención de los datos de la temperatura cutánea nocturna, se desarrolló un script específico (polar\_temperatur.py) que conecta la API de Polar (Elixir™ Biosensing (Beta)) y hace todo el proceso de autenticación automáticamente.

Lo que hace es solicitar los datos de temperatura del cuerpo usando el *endpoint* /bodytemperature para un rango de fechas específico, tal como se muestra en la siguiente función cliente de la API:

```

# Realiza una petición GET al endpoint de temperatura corporal
def get_temperature_data(self, start_date, end_date):
    params = {"from": start_date.isoformat(), "to":
    end_date.isoformat()}
    return self._make_request("bodytemperature", params)

```

En vez de guardar todos los miles de muestras crudas, el script las procesa usando Pandas y calcula estadísticas: temperatura media, máxima, mínima, desviación estándar y una métrica importante llamada amplitud de temperatura (diferencia entre la temperatura máxima y mínima).

```
# Procesamiento de las muestras para calcular estadísticas
diarias
df = pd.DataFrame(samples)
temp_series = df['temperature_celsius']

stats = {
    'date': measurement.get('start_time', '')[:10],
    'temp_mean': temp_series.mean(),
    'temp_max': temp_series.max(),
    'temp_min': temp_series.min(),
    'temp_amplitude': temp_series.max() - temp_series.min(),
    'num_samples': len(df)
}
daily_stats.append(stats)
```

Al final, guarda todo esto ya procesado en un archivo CSV llamado `body_temperature_summary.csv`, lo que facilita el trabajar con los datos ya que los transforma en valores diarios útiles y más fáciles de analizar.

## 5.2 Unificación y limpieza de datos

Después de recoger los datos, que estaban repartidos en varios archivos CSV, uno para cada parámetro importante del estudio, es necesario unirlos para poder analizarlos.

Por eso se creó un script llamado `unir_BBDD.py` usando Pandas. El proceso fue:

1. **Carga de archivos:** Se leen todos los CSV como DataFrames.
2. **Fusión:** Usando `pd.merge`, se fueron uniando los DataFrames uno por uno, usando la columna `date` como clave común.
3. **Selección de variables:** Del resultado se eligieron solo las columnas más importantes para la estimación de la fragilidad, como por ejemplo `active-steps`, `heart_rate_variability_avg`, `sleep_score` y `temp_amplitude`.

Al final, se generó un solo archivo llamado `datos_smartwatch.csv`, ya listo para aplicar el modelo de clasificación.

## 5.3 Generación de Datos Sintéticos

### 5.3.1 Justificación

Una de las principales limitaciones durante la recolección de datos fue la poca cantidad de información disponible para entrenar un modelo de Machine Learning sólido, aunque los datos reales eran de buena calidad, eran escasos y estaban desbalanceados: habían muchos más días clasificados como ‘robustos’ o ‘pre-frágiles’ que como ‘frágiles’. Para solucionar esto y evitar que el modelo se sobreentrenara (*overfitting*), se decidió ampliar el dataset creando datos sintéticos.

### 5.3.2 Metodología de generación

En lugar de recurrir a un modelo de lenguaje, se optó por desarrollar un script en Python (datosSinteticos.py) que genera de forma procedural un dataset completo, utilizando las librerías **Pandas** y **NumPy**. Este enfoque proporciona un control total sobre las propiedades y la distribución de los datos generados.

El proceso de generación es el siguiente:

1. **Generación aleatoria de características:** El script recorre un número definido de sujetos y días, y para cada día genera valores aleatorios para distintas variables fisiológicas como active-steps, heart\_rate\_avg, sleep\_score, entre otras, dentro de rangos considerados clínicamente plausibles. El siguiente fragmento de código del script datosSinteticos.py muestra esta lógica:

```
# Generación de valores aleatorios dentro de rangos plausibles
steps = np.random.randint(500, 13000)
hr_avg = np.random.uniform(55, 85)
hrv_avg = np.random.uniform(15, 65)
sleep_score = np.random.uniform(45, 90)
```

2. **Asignación de etiquetas de fragilidad:** Una vez generadas las características de una fila (es decir, un día de un sujeto), el script aplica una función de clasificación llamada `classify_row` para determinar la categoría de fragilidad correspondiente. Es importante destacar que esta función es exactamente la misma que se emplea en el script `clasificacion_fragilidad.py`, lo que garantiza coherencia con los criterios de evaluación del proyecto.

```
# El diccionario 'row' contiene todas las
características generadas previamente

# Asignar una etiqueta de fragilidad basada en las
reglas del modelo
row['frailty_status'] = classify_row(row)
data.append(row)
```

Gracias a este enfoque, la etiqueta de fragilidad no se asigna de forma aleatoria, sino como resultado directo de los valores generados, en total alineación con la lógica del modelo por reglas. El resultado final es el fichero `datasetIAML.csv`, un dataset sintético, variado y completamente preparado para combinarse con los datos reales.

### 5.3.3 Validación y Curación

Los datos generados por la IA fueron revisados para asegurar que los valores se mantuvieran dentro de los rangos fisiológicamente plausibles y que no introdujeran artefactos o patrones anómalos.

## 5.4 Clasificación de la Fragilidad

La etapa final del estudio consistió en aplicar un modelo de clasificación para estimar el nivel diario de fragilidad a partir de los datos integrados. Para ello, se desarrolló un script `clasificacion_fragilidad.py` (ANEXO B), que implementa un sistema de puntuación basado en reglas, inspirado en los criterios del fenotipo de fragilidad.

El modelo analiza cuatro variables claves extraídas de los registros del smartwatch. A cada una se les asigna una puntuación entre 0 (frágil), 1 (pre-frágil) y 2 (robusto), en función de ciertos umbrales definidos. La suma de estas puntuaciones determina la clasificación del estado de fragilidad para cada día.

### 5.4.1 Criterios de puntuación

#### 5.4.1.1 Actividad física (Pasos activos)

Esta métrica mide el nivel de movimiento diario. Un mayor número de pasos indica una mejor condición física:

- +2 puntos: si `active-steps > 6000`
- +1 punto: si `active-steps > 2500`

#### **5.4.1.2 Resiliencia fisiológica (HRV)**

La `heart_rate_variability_avg` (HRV) refleja la capacidad del cuerpo para recuperarse y adaptarse al estrés. Una HRV más alta es mejor:

- +2 puntos: si  $HRV > 35ms$
- +1 punto: si  $HRV > 25ms$

#### **5.4.1.3 Estrés fisiológico (Frecuencia Cardíaca Nocturna)**

La `heart_rate_avg` (HR) durante el sueño es un indicador del nivel de recuperación. Una frecuencia cardíaca más baja indica un mejor estado de reposo:

- +2 puntos: si  $HR < 65bpm$
- +1 punto: si  $HR < 72 bpm$

#### **5.4.1.4 Calidad del descanso (Puntuación del sueño)**

La `sleep_score` evalúa la calidad del sueño. Una puntuación más alta indica un descanso más reparador:

- +2 puntos: si `sleep_score` es mayor de 75.
- +1 punto: si `sleep_score` es mayor de 60.

#### **5.4.2 Clasificación final**

La suma total de puntos (máximo 8) permite etiquetar cada día según el siguiente criterio:

- Robusto: 6 a 8 puntos
- Pre-frágil: 3 a 5 puntos
- Frágil: 0 a 2 puntos

El script aplica esta lógica a cada fila del archivo de datos unificados, añade una nueva columna llamada `frailty_status` con la clasificación correspondiente, y guarda el resultado en un archivo final CSV

## 5.5 Modelo de Machine Learning (ML): XGBoost

Como ya se mencionó anteriormente, el modelo ML seleccionado fue XGBoost (Extrem Gradient Boosting) ya que fue el modelo que dio mejores resultados a la hora de detectar la fragilidad.

El proceso se dividió en tres etapas principales: preparación del dataset, entrenamiento y evaluación del modelo, y finalmente, la exportación de un pipeline de producción.

### 5.5.1 Preparación del dataset

El primer paso fue generar un único conjunto de datos unificado, limpio y listo para ser utilizado en el entrenamiento del modelo. Esta tarea se llevó a cabo de forma automatizada mediante el script `prepararDataset.py`, que ejecutó las siguientes acciones:

1. Fusión de datos: Se cargaron los ficheros `datasetRealML.csv` (datos reales) y `datasetIAML.csv` (datos sintéticos) y se combinaron en un único `DataFrame`. Esta estrategia de *data augmentation* permitió aumentar el volumen total de registros y equilibrar la distribución entre clases.

```
# Se unen los dos dataframes en uno solo
df_combinado = pd.concat([df_real, df_sintetico],
                           ignore_index=True)
```

1. Limpieza de datos: Para asegurar la calidad del conjunto final, se eliminaron todas las filas que contenían valores nulos (NaN).
2. Codificación de la variable objetivo: La variable objetivo `frailty_status`, originalmente en formato texto, se transformó a valores numéricos para facilitar su interpretación por el modelo. La codificación fue la siguiente:
  - i. 'fragil' → 0
  - ii. 'pre-fragil' → 1
  - iii. 'robusto' → 2

```

# Se crea el mapa para la codificación
mapa_fragilidad = {
    'robusto': 2,
    'pre-fragil': 1,
    'fragil': 0
}
# Se aplica el mapa a la columna 'frailty_status'
df_limpio['frailty_status'] =
df_limpio['frailty_status'].map(mapa_fragilidad)

```

Como resultado, se generó el archivo `dataset_preparado.csv`, que se utilizó como entrada en la fase de entrenamiento del modelo de clasificación.

## 5.5.2 Entrenamiento y Evaluación

Esta etapa, llevada a cabo con el script `modeloXGBoost.py`, tuvo como objetivo entrenar el clasificador y evaluar su rendimiento de forma precisa y controlada.

Para garantizar una evaluación realista del modelo, se aplicaron dos estrategias claves:

1. División por usuario: En lugar de hacer una división aleatoria tradicional, los datos se separaron en conjuntos de entrenamiento y prueba usando la variable `id_usuario`. Esto evitó el *data leakage*, ya que las observaciones de un mismo usuario no se mezclaron entre los dos conjuntos. Así, el modelo fue evaluado como si se enfrentara a usuarios totalmente nuevos, lo que representa un escenario más realista.

```

División de Datos por Usuario (Train/Test)
user_ids = df['id_usuario'].unique()
train_user_ids, test_user_ids = train_test_split(user_ids,
test_size=0.25, random_state=42)

train_indices =
df[df['id_usuario'].isin(train_user_ids)].index
test_indices = df[df['id_usuario'].isin(test_user_ids)].index

X_train, X_test = X.loc[train_indices], X.loc[test_indices]
y_train, y_test = y.loc[train_indices],
y.loc[test_indices]

```

2. Balanceo con SMOTE: Debido al bajo número de ejemplos etiquetados como ‘frágil’, se utilizó la técnica **SMOTE (Synthetic Minority Over-sampling Technique)** para equilibrar las clases. Este proceso se aplicó **solo al conjunto**

**de entrenamiento**, manteniendo el conjunto de prueba con la distribución original. De esta forma, se logró un entrenamiento más robusto sin afectar la validez de la evaluación final.

```
# Aplicar SMOTE (Solo a los datos de entrenamiento)
smote = SMOTE(random_state=42)
X_train_resampled, y_train_resampled =
smote.fit_resample(X_train, y_train)
```

El modelo XGBoost se inicializó y entrenó con los datos de entrenamiento ya balanceados.

```
# Se inicializa el clasificador XGBoost
model = XGBClassifier(objective='multi:softmax',
num_class=3, use_label_encoder=False,
eval_metric='mlogloss', random_state=42)

# Se entrena el modelo con los datos balanceados
model.fit(X_train_resampled, y_train_resampled)
```

### 5.5.3 Creación y exportación del Pipeline final

La fase final, llevada a cabo mediante el script `exportMLXGBoost.py`, se centró en dejar el modelo listo para su uso en producción o para integrarlo fácilmente en otras aplicaciones.

Para ello, se creó un Pipeline de **Scikit-learn**. Este objeto agrupa todo el flujo del modelo: desde el preprocesamiento de los datos hasta la predicción final con el clasificador XGBoost. El pipeline fue entrenado utilizando **todo el conjunto de datos** (ya balanceado previamente con SMOTE), con el objetivo de aprovechar al máximo la información disponible y optimizar el rendimiento del modelo.

```
# Unión del el preprocesador y el modelo en un único Pipeline
final_pipeline = Pipeline(steps=[('preprocessor', preprocessor),
                                ('classifier', model)])
```

Una vez entrenado, el pipeline completo se guardó en un único archivo llamado `fragility_pipeline.joblib` usando la librería **joblib**. Este archivo contiene tanto el modelo como los pasos de preprocesamiento, lo que permite reutilizarlo fácilmente para hacer predicciones futuras sobre nuevos datos, sin necesidad de volver a entrenar o escribir código adicional.

```
# Guardar el Pipeline
pipeline_filename = 'fragility_pipeline.joblib'
joblib.dump(final_pipeline, pipeline_filename)
```



## 5.6 Aplicación interactiva

Para cerrar el proyecto y hacerlo más útil para cualquier persona (aunque no sepa programar), se creó una aplicación web interactiva usando la librería **Streamlit**. Esta app, llamada `app.py`, permite que cualquier usuario pueda cargar sus datos del smartwatch y obtener una estimación de su estado de fragilidad sin tener que escribir ni una línea de código.

La aplicación tiene varias pestañas y dos formas principales de usarla. Internamente, la app llama a otros scripts de Python (como `prepararDF.py` y `limpiar_dataset.py`) para preparar los datos antes de hacer la predicción. Para ejecutar estos scripts, se usa una función que lanza subprocessos de Python:

```
# app.py
def run_script(script_name, args=[]):
    """Ejecuta un script externo y muestra su salida."""
    command = ["python", script_path] + args
    try:
        result = subprocess.run(
            command, capture_output=True, text=True, check=True,
            encoding='latin-1'
        )
        st.info(f"Salida de '{script_name}':\n{result.stdout}")
        return True
    # ... manejo de errores ...
    # ... manejo de errores ...
```

La primera opción (OPCIÓN A, Figura x) es para usuarios que tienen sus datos divididos en 4 ficheros CSV: actividad diaria, recuperación, sueño y temperatura.

1. El usuario pone su edad y sube los cuatro archivos.
2. La app llama al script `prepararDF.py`, que une los ficheros por fecha y elimina los días con datos incompletos.
3. Luego, se añade la edad al dataset resultante y se pasa al modelo para que haga la predicción.

La segunda (OPCIÓN B, Figura x) es para quienes ya tienen un único archivo con todos los datos necesarios, pero con algunos valores faltantes (NaN).

1. El usuario sube ese único fichero.
2. La app llama al script `limpiar_dataset.py`, que limpia los datos rellenando los NaN con la mediana (si es número) o con la moda (si es texto).

3. El dataset limpio se usa directamente para hacer las predicciones.

Por último, independientemente de qué opción se utilizó, la predicción se hace de la misma manera. La app carga el modelo previamente entrenado (`fragility_pipeline.joblib`) y usa el método `.predict_proba()` para calcular las probabilidades de cada clase:

```
# app.py
# Carga del pipeline entrenado
pipeline = joblib.load(os.path.join(APP_DIR, PIPELINE_FILE))

# Obtención de las probabilidades para cada clase
probabilities = pipeline.predict_proba(df)
```

Después, los resultados se muestran de forma clara y visual para el usuario:

- Una **tabla** con la predicción de fragilidad para cada fecha y las probabilidades de cada clase.
- Un **gráfico de barras** que resume cuántos días fueron clasificados como 'Frágil', 'Pre-frágil' o 'Robusto'.
- Un **gráfico de líneas** que muestra cómo evoluciona el estado de fragilidad con el tiempo:

```
# app.py
# Generar el gráfico de línea para la evolución
temporal
st.line_chart(plot_df['predicted_frailty'])
```

Esta app permite a cualquier persona visualizar sus datos y conocer su estado de salud diaria de forma simple, rápida y sin complicaciones técnicas.

Para poder lanzar la interfaz se debe acceder por terminal a la ubicación del fichero `app.py` y escribir: `streamlit run app.py`, con esto te solicita un correo electrónico y automáticamente lanza la aplicación:

# Estimador de Fragilidad Basado en Datos de Smartwatch

[Instrucciones](#) [Predecir desde 4 Archivos](#) [Examinar Dataset Completo](#)

## Instrucciones de Uso y Formato

### Opción A: Predecir desde 4 Archivos

1. **Introduce la Edad:** Escribe la edad del sujeto en el campo numérico.
2. **Carga los 4 Archivos:** Sube cada uno de los ficheros CSV correspondientes.
3. **Ejecuta:** Pulsa el botón "Unir, Limpiar y Predecir".

La aplicación unirá los archivos por fecha, eliminará los días que no tengan datos completos en los 4 ficheros, añadirá la edad y realizará la predicción.

### Opción B: Examinar Dataset Completo

1. **Prepara tu Archivo:** Asegúrate de que tu fichero CSV contiene **todas** las columnas necesarias que usa el modelo, incluyendo `date` y `age`.
2. **Carga el Archivo:** Sube el fichero CSV completo.
3. **Ejecuta:** Pulsa el botón "Limpiar y Predecir Dataset".

La aplicación tomará tu archivo, rellenará cualquier valor `NaN` que encuentre usando la mediana (para números) o la moda (para texto), y luego realizará la predicción.

### Columnas Requeridas por el Modelo

```
# El modelo necesita obligatoriamente estas columnas:  
date, age, active-steps, active-calories, calories, duration_minutes,  
heart_rate_avg, heart_rate_variability_avg, ans_charge, sleep_score,  
light_sleep_min, deep_sleep_min, rem_sleep_min, interruptions_min,  
breathing_rate_avg, temp_amplitude
```

**Figura 5.6-A. Captura de pantalla de las instrucciones necesarias para utilizar la app interactiva para la predicción de la fragilidad.**

# Estimador de Fragilidad Basado en Datos de Smartwatch

[Instrucciones](#) [Predecir desde 4 Archivos](#) [Examinar Dataset Completo](#)


### Opción A: Predecir uniendo 4 archivos

Carga los 4 ficheros CSV por separado. La edad se introduce manualmente.

Introduce la Edad del Usuario


75

Fichero de Actividad

 Drag and drop file here  
Limit 200MB per file • CSV


Browse files

Fichero de Sueño

 Drag and drop file here  
Limit 200MB per file • CSV


Browse files

Fichero de Recuperación

 Drag and drop file here  
Limit 200MB per file • CSV

Browse files

Fichero de Temperatura

 Drag and drop file here  
Limit 200MB per file • CSV

Browse files

Unir, Limpiar y Predecir

**Figura 5.6-B. Captura de pantalla de la app interactiva para la predicción de la fragilidad con diferentes ficheros.**


## Estimador de Fragilidad Basado en Datos de Smartwatch

[Instrucciones](#) [Predecir desde 4 Archivos](#) [Examinar Dataset Completo](#)

### Opción B: Predecir desde un Dataset Completo

Carga un único fichero CSV que ya contenga todas las columnas, incluida la edad.

Cargar Fichero de Datos Consolidado

 Drag and drop file here  
Limit 200MB per file • CSV

[Browse files](#)

[Limpiar y Predecir Dataset](#)

**Figura 5.6-C. Captura de pantalla de la app interactiva para la predicción de la fragilidad con un único fichero.**

## 5.7 Librerías utilizadas

A continuación, se describen, brevemente, las librerías de Python utilizadas para el proyecto.

### 5.7.1 Pandas

Herramienta fundamental de Python para el análisis y manipulación de datos, especialmente datos tabulares como hojas de cálculo o tablas SQL.

### 5.7.2 Request

Es la librería estándar de facto en Python para realizar peticiones HTTP. Permite enviar y recibir datos de servidores web de una manera muy sencilla, siendo fundamental para interactuar con APIs como la de Polar.

### 5.7.3 PyYAML

Se utiliza para trabajar con archivos de formato YAML (.yaml). Su función principal es cargar (leer) archivos de configuración YAML en objetos de Python y volcarlos (escribir) de vuelta a formato YAML.

### 5.7.4 Flask

Es un "microframework" para el desarrollo web en Python. Permite crear aplicaciones web de forma rápida y con un código mínimo. En este proyecto, se usa para levantar un servidor web temporal que gestione la redirección de la autorización OAuth2.

### **5.7.5 Scikit-learn**

Biblioteca de aprendizaje automático gratuita y de código abierto para el lenguaje de programación Python. Cuenta con algoritmos de clasificación, regresión, clustering y reducción de dimensionalidad.

### **5.7.6 Matplotlib**

Se usa para crear gráficos, en este caso para visualizar la matriz de confusión y la importancia de las características.

### **5.7.7 Seaborn**

Complementa a Matplotlib con gráficos más estilizados. Aquí genera el heatmap de la matriz de confusión y el gráfico de barras de la importancia de las características.

### **5.7.8 Imblearn**

Técnica para balancear clases desequilibradas mediante sobre-muestreo sintético. Se aplica al conjunto de entrenamiento para mejorar el aprendizaje del modelo.

### **5.7.9 Xgboost**

Clasificador principal del script. Es un modelo de gradient boosting eficiente y potente, especializado en tareas de clasificación como la de este proyecto.

### **5.7.10 Streamlit**

Es un framework de código abierto que permite crear y compartir aplicaciones web para ciencia de datos y machine learning de forma rápida y sencilla. Convierte scripts de datos en aplicaciones interactivas con widgets como botones, sliders y gráficos, sin necesidad de tener conocimientos avanzados de desarrollo web (HTML, CSS o JavaScript).

Es la librería central para construir la aplicación web interactiva (app.py).

### **5.7.11 Joblib**

Es una librería diseñada para la computación paralela en Python. Se utiliza comúnmente para guardar y cargar objetos de Python, como modelos de machine learning ya entrenados, de manera eficiente. También proporciona herramientas para ejecutar funciones en paralelo, lo que puede acelerar significativamente los cálculos

### **5.7.12 Os**

Es otra librería estándar de Python que proporciona una forma de interactuar con el sistema operativo. Permite realizar operaciones como crear o eliminar carpetas, obtener rutas de archivos, y trabajar con variables de entorno, independientemente del sistema operativo en el que se ejecute el código (Windows, macOS o Linux).

### **5.7.13 Argparse**

Es una librería estándar de Python (viene incluida por defecto) que se utiliza para escribir programas de línea de comandos amigables. Permite definir los argumentos que el programa requiere, los procesa desde la terminal y genera mensajes de ayuda automáticamente.

### **5.7.14 Subprocess**

Esta librería estándar de Python permite ejecutar nuevos procesos o programas externos desde un script de Python. Se utiliza para correr otros comandos del sistema, capturar su salida y gestionar su ejecución, como si los estuvieras escribiendo directamente en la terminal.

## **5.8 Material utilizado**

Para el desarrollo del estudio se utilizó un smartwatch Polar Vantage V3, proporcionado por los profesores. Las funcionalidades de este smartwatch son:

- Entrenamiento y recuperación:
  - Training Load Pro™
  - Fuentes de energía
  - Running Power en la muñeca
  - FitSpark®
  - FuelWise™
  - Resumen semanal de entrenamiento
  - Métricas de natación
  - Running Program
  - Planificador de la temporada

- Objetivos de entrenamiento
- Indicaciones por voz
- Guía de recuperación
- Velocidad vertical y VAM
- Resumen de la ruta en el Resumen del entrenamiento
- Estilos de natación en el resumen del entrenamiento
- Recovery Pro™
- Actividad:
  - Registro de la actividad 24/7
  - Recuento de pasos
- Sueño y bienestar:
  - SleepWise™
  - Nightly Recharge™
  - Sleep Plus Stages™
  - Serene™
  - SpO2
  - ECG en la muñeca
  - Temperatura nocturna de la piel
- Entrenamiento al aire libre y navegación:
  - Sistem global de navegación por satélite
  - Indicaciones giro a giro con komoot
  - Track Back
  - Hill Splitter™
  - Perfiles de ruta y altimetría
  - Seguimiento de rutas
  - Regresar a inicio
  - Mapas
  - Rutas planificadas y Navegación mediante rastros de migas de pan
  - Velocidad vertical y VAM
  - Altímetro
  - Puntos de interés
- Test:
  - Running Test

- Fitness Test
- Walking Test
- Cycling Test
- Orthostatic Test
- Leg Recovery Test
- Utilities:
  - Flashlight
  - Pantallas personalizables de distintos colores
  - Horas de luz
  - El tiempo
  - Polar Flow
  - Controles de música
  - Notificaciones
  - Encuentra mi teléfono
  - Notificaciones internas
  - Carga y sigue entrenando
- Hardware:
  - Batería de larga duración
  - Elixir™
  - GPS dual
  - Altímetro
- Conectividad:
  - Modo sensor de frecuencia cardíaca





**Figura 5.8-A.** Polar Vantage V3

## 6 Resultados

En esta sección se presentan los resultados obtenidos tras evaluar el modelo de clasificación XGBoost utilizando el conjunto de datos de prueba, compuesto por registros de usuarios que no participaron en la fase de entrenamiento. El análisis se enfoca tanto en el rendimiento general del modelo como en su comportamiento frente a cada una de las clases de fragilidad. Además, se examina la relevancia de las variables fisiológicas utilizadas en la predicción.

En cuanto al rendimiento general, se puede ver que el modelo alcanzó una **precisión global (accuracy) del 93.33%**, lo cual indica una alta capacidad para predecir correctamente el estado diario de fragilidad.

Para entender mejor el rendimiento por clase, se generó un informe de clasificación que desglosa precisión, recall, F1-score y soporte (support) por categoría:

**Tabla 6-A.**


*Tabla con los resultados obtenidos del entrenamiento del modelo XGBoost para la predicción de la fragilidad.*

	Precisión	Recall	F1-score	Support
<b>Frágil (0)</b>	0.78	0.78	0.78	18
<b>Pre-frágil (1)</b>	0.95	0.94	0.94	111
<b>Robusto (2)</b>	0.96	0.97	0.96	66
Accuracy			0.93	195
<b>Macro avg</b>	0.89	0.89	0.89	195
<b>Weighted avg</b>	0.93	0.93	0.93	195

Conclusiones principales:

- El modelo se desempeña especialmente bien con las clases Pre-frágil y Robusto, con F1-scores de 0.94 y 0.96, respectivamente.
- El rendimiento en la clase Frágil es algo inferior (F1-score de 0.78), lo cual era esperable debido al reducido número de ejemplos en esa categoría (solo 18), lo que representa un reto para el modelo al ser una clase minoritaria.

La matriz de confusión permite visualizar con mayor detalle los aciertos y errores de clasificación:



**Figura 6-A. Matriz de confusión del modelo XGBoost.**


Se puede deducir que la mayoría de los errores se producen entre clases vecinas, como *Frágil* y *Pre-frágil*, lo cual sugiere que el modelo es sensible a los matices entre estados intermedios. Además, no se observaron confusiones entre clases extremas (por ejemplo, *Frágil* clasificado como *Robusto*), lo que refleja la solidez del modelo para distinguir claramente entre estados opuestos de salud.

Por otra parte, se analizó la importancia que el modelo otorga a cada una de las variables fisiológicas durante la predicción. Esto permite entender qué características tuvieron más peso a la hora de estimar la fragilidad:

**Tabla 6-B.**

*Tabla con las características que tuvieron más peso en la estimación de la fragilidad*

Características	Importancia
heart_rate_variability_avg	0.250738
active-steps	0.166231
heart_rate_avg	0.138841
sleep_score	0.122251
active-calories	0.065376



**Figura 6-B.** Gráfico que representa la importancia de cada variable a la hora de estimar la fragilidad.

Como conclusión se puede decir que las cuatro variables más influyentes — **variabilidad de la frecuencia cardíaca, pasos activos, frecuencia cardíaca media y puntuación del sueño**— coinciden exactamente con las seleccionadas previamente para el modelo basado en reglas. Este resultado valida la hipótesis original del proyecto: estas métricas son pilares fundamentales para estimar el nivel de fragilidad a partir de datos recogidos por un smartwatch

## 7 Discusión

Los resultados obtenidos durante la fase de modelado no solo corroboran la viabilidad técnica del proyecto, sino que también ofrecen evidencias relevantes sobre la relación existente entre las métricas recogidas por un smartwatch y el estado de fragilidad de una persona.

El modelo XGBoost alcanzó una precisión global del 93.33%, lo cual pone de manifiesto el alto poder predictivo de las variables fisiológicas y de actividad incluidas en el estudio. Este resultado respalda sólidamente la hipótesis principal de este trabajo: es factible desarrollar un sistema de estimación de fragilidad que sea no invasivo, continuo y basado en datos recolectados de forma pasiva mediante dispositivos de uso cotidiano.

Desde una perspectiva más detallada, el análisis por clases revela que el modelo identifica con gran precisión los estados “robusto” (F1-score = 0.96) y “pre-frágil” (F1-score = 0.94). La clase “frágil”, por su parte, presenta un F1-score de 0.78. Si bien este valor sigue siendo satisfactorio, es sensiblemente inferior a los anteriores. Esta diferencia puede atribuirse principalmente al desbalance de clases en el conjunto de datos, dado que el número de muestras correspondientes a personas frágiles es considerablemente menor. A pesar de esta limitación, la matriz de confusión aporta una observación clave: no se producen errores de clasificación entre clases extremas. Es decir, ningún caso “frágil” ha sido clasificado como “robusto” y viceversa. Este hecho refuerza la confianza en la aplicabilidad del modelo, al garantizar que es capaz de distinguir correctamente entre los estados de salud más alejados.

Uno de los hallazgos más relevantes del estudio se refiere a la importancia relativa de las características utilizadas por el modelo. Las cuatro variables que XGBoost identificó como más influyentes —heart\_rate\_variability\_avg, active-steps, heart\_rate\_avg y sleep\_score— coinciden exactamente con las seleccionadas para el modelo basado en reglas

desarrollado en fases anteriores. Esta convergencia no debe interpretarse como un simple resultado anecdótico, sino como una validación empírica del enfoque teórico del proyecto. El modelo de Machine Learning, de forma autónoma, ha confirmado que la resiliencia fisiológica (medida mediante la variabilidad de la frecuencia cardíaca), la actividad física, el estrés fisiológico nocturno (reflejado en la frecuencia cardíaca media) y la calidad del descanso son factores clave para la estimación de la fragilidad.

No obstante, es necesario reconocer las limitaciones de este trabajo. En primer lugar, la etiquetación de los datos utilizada como referencia (ground truth) se ha basado en un modelo de reglas heurísticas, en lugar de en diagnósticos clínicos validados. Por tanto, el modelo de aprendizaje automático ha aprendido a reproducir y generalizar esas reglas con eficacia, pero no ha sido entrenado sobre información clínica directa. En segundo lugar, aunque el uso de datos sintéticos fue fundamental para aumentar el volumen y el equilibrio del conjunto de entrenamiento, esto introduce una posible limitación en la capacidad de generalización del modelo. En consecuencia, será necesario validar el sistema con una cohorte más amplia y diversa de datos reales en futuras fases del proyecto para garantizar su fiabilidad en contextos clínicos reales.

## 8 Conclusión

El presente Trabajo de Fin de Grado ha tenido como objetivo el desarrollo y validación de una metodología integral para la estimación del estado de fragilidad a partir de datos recopilados mediante smartwatches comerciales. A lo largo del proyecto se han abordado todas las fases del ciclo de ciencia de datos —adquisición, limpieza, análisis exploratorio, modelado y despliegue—, lo que ha permitido alcanzar una solución completa y funcional. De este proceso, se extraen las siguientes conclusiones principales:

- **Viabilidad técnica demostrada:** Se ha comprobado que es posible estimar el estado de fragilidad de forma no invasiva, continua y automatizada, utilizando variables extraídas de dispositivos de monitorización comercial. El modelo XGBoost desarrollado logró una precisión del 93.33% sobre datos de prueba, lo que respalda la factibilidad del enfoque.
- **Confirmación de indicadores clave:** Tanto el modelo basado en reglas como el modelo de aprendizaje automático identificaron como principales predictores de la fragilidad a la variabilidad de la frecuencia cardíaca, los pasos activos, la frecuencia cardíaca nocturna y la calidad del sueño. Esta coincidencia constituye una validación empírica de las hipótesis teóricas formuladas en fases iniciales del trabajo.
- **Robustez del modelo de clasificación:** Un aspecto especialmente destacable es que el modelo no incurre en errores de clasificación entre estados extremos (es decir, no clasifica a personas frágiles como robustas ni viceversa). Esta característica incrementa la confianza en su aplicabilidad real, al minimizar el riesgo de diagnósticos erróneos en los casos más críticos.
- **Desarrollo de una solución integral:** Se ha construido un sistema completo que incluye:
  - Extracción de datos desde la API de Polar,

- Generación de datos sintéticos,
- Entrenamiento del modelo predictivo,
- Despliegue final en una aplicación web interactiva mediante Streamlit, accesible para usuarios no técnicos.

Este enfoque integral permite no solo demostrar la viabilidad técnica del modelo, sino también su potencial como herramienta práctica de apoyo a la toma de decisiones en el ámbito de la salud preventiva.



## 9 Trabajo futuro

A partir de los resultados obtenidos, se plantean diversas líneas de investigación y desarrollo que podrían enriquecer y consolidar los avances logrados en este trabajo:

- **Validación clínica:** Como siguiente paso fundamental, se propone contrastar las predicciones del modelo frente a diagnósticos clínicos realizados por profesionales de geriatría, utilizando criterios estándar como el fenotipo de Fried. Esta validación permitiría confirmar la utilidad del sistema en contextos médicos reales.
- **Ampliación y diversificación del dataset:** Recopilar datos de una población más amplia y diversa —tanto en edad como en condiciones de salud— permitiría mejorar la generalización del modelo, así como mitigar el desbalance de clases observado en la muestra actual.
- **Exploración de modelos temporales:** Se plantea como línea futura la incorporación de modelos de Deep Learning capaces de analizar series temporales completas (por ejemplo, redes LSTM o Transformers), con el objetivo de captar dinámicas longitudinales que el enfoque actual, basado en registros diarios independientes, no contempla.
- **Integración en tiempo real:** Una evolución natural del sistema sería adaptar la aplicación web para conectarse directamente a la API de Polar, permitiendo así un monitoreo continuo y en tiempo real del estado de fragilidad del usuario, lo cual tendría un gran valor en entornos de atención domiciliaria o envejecimiento activo.

## 10 Bibliografía y referencias

[1] Fried LP, Ferrucci L, Darer J, Williamson JD, Anderson G. Untangling the concepts of disability, frailty, and comorbidity: implications for improved targeting and care. *J Gerontol A Biol Sci Med Sci*. 2004; 59(3):255-263.

[2] Manrique-Espinoza, B., & Salinas-Rodríguez, A. (2018). Healthcare Costs of Frailty: Implications for Long-term Care. *Healthcare*, 6(4), 138.

[3] Cesari, M., Araujo de Carvalho, I. A., Ambler, G., Lichtenberg, R., & Sinclair, A. J. (2016). Frailty in older persons—a position paper of the European Society of Geriatric Medicine. *European Geriatric Medicine*, 7(1), 12-19.

[4] Romero-Ortuno, R. (2013). Frailty in heart failure: too frail to function. *Journal of Cardiac Failure*, 19(3), 194-196.

[5] Pérez-Sousa, S., Valero-García, A., Prieto-Prieto, J., Núñez-Naveira, L., Martínez-Isasi, S., & Alonso-Bouzas, C. (2018). Wearable devices for the detection of frailty syndrome: A systematic review. *BMC geriatrics*, 18(1), 179.

[6] Doody, P., Lord, J. M., Greig, C. A., & Whittaker, A. C. (2023). Frailty: Pathophysiology, Theoretical and Operational Definition(s), Impact, Prevalence, Management and Prevention, in an Increasingly Economically Developed and Ageing World. *Gerontology*, 69(8), 927–945. <https://doi.org/10.1159/000528561>

[7] Medical University of South Carolina. Frailty: A New Predictor of Outcome as We Age. <https://muschealth.org/medical-services/geriatrics-and-aging/healthy-aging/frailty>

[8] British Geriatrics Society. Introduction to Frailty, Fit for Frailty Part . <https://www.bgs.org.uk/resources/introduction-to-frailty>

[9] Wikipedia. Frailty syndrome. [https://en.wikipedia.org/wiki/Frailty\\_syndrome](https://en.wikipedia.org/wiki/Frailty_syndrome)

[10] Cleveland Clinic. Frailty: Definition & Scores. <https://my.clevelandclinic.org/health/diseases/frailty>

[11] John Young. (2013) Frailty – what it means and how to keep well over the winter months. NHS England. <https://www.england.nhs.uk/blog/frailty/>

[12] Xue Q. L. (2011). The frailty syndrome: definition and natural history. *Clinics in geriatric medicine*, 27(1), 1–15. <https://doi.org/10.1016/j.cger.2010.08.009>

[13] Allison, R., 2nd, Assadzandi, S., & Adelman, M. (2021). Frailty: Evaluation and Management. *American family physician*, 103(4), 219–226.

[14] Mobian. Monitorización remota de la salud de las personas mayores: un enfoque tecnológico para el cuidado de las personas mayores. <https://mobian.studio/es/remote-monitoring-of-elderly-people-health/>

[15] Autor/es: Arturo Gómez Pellín, Sergio Jiménez Monferrer, José Francisco Pedrero Sánchez, María Amparo López Vicente, José David Garrido Jaén, Carlos Atienza Vicente (26 de Diciembre de 2023). «AI3cord: dispositivos IoT e Inteligencia Artificial para monitorizar y prevenir la fragilidad en personas mayores». Revista de Biomecánica nº 70. <https://www.ibv.org/actualidad/ai3cord-dispositivos-iot-e-inteligencia-artificial-para-monitorizar-y-prevenir-la-fragilidad-en-personas-mayores/>

[16] Consejo COLEF. PowerFrail: la app para evaluar la potencia muscular y fragilidad de nuestros mayores. <https://www.consejo-colef.es/post/gicpefd00221-02>

[17] Andrea Castillo. La Cátedra Cuatroochenta inicia una colaboración con la herramienta de rehabilitación a distancia Kineactiv para cooperar en una investigación que podría ayudar al personal sanitario a detectar la aparición de los primeros síntomas de incapacidad y vulnerabilidad. Noviembre 23, 2021. <https://catedra.cuatroochenta.com/camaras-3d-deteccion-fragilidad/>

[18] Matteo Leghissa, Álvaro Carrera, Carlos Á. Iglesias, FRELSA: A dataset for frailty in elderly people originated from ELSA and evaluated through machine learning models, *International Journal of Medical Informatics*, Volume 192, 2024, 105603, ISSN 1386-5056, <https://doi.org/10.1016/j.ijmedinf.2024.105603>.

[19] Menéndez-González, L., Izaguirre-Riesgo, A., Tranche-Iparraguirre, S., Montero-Rodríguez, Á., & Orts-Cortés, M. I. (2021). Prevalencia y factores asociados de fragilidad

en adultos mayores de 70 años en la comunidad. *Atención Primaria*, 53(10). doi:10.1016/j.aprim.2021.102128

[20] Guerrero Rojas, G. (2022). Síndrome de fragilidad en el adulto mayor: una revisión sistematizada. *Revista Mexicana De Enfermería Cardiológica*, 29(3), 97-111. Recuperado a partir de <https://ciberindex.com/c/rmec/e29305>

[21] Doherty, C., Baldwin, M., Keogh, A., Caulfield, B., & Argent, R. (2024). Keeping Pace with Wearables: A Living Umbrella Review of Systematic Reviews Evaluating the Accuracy of Consumer Wearable Technologies in Health Measurement. *Sports Medicine*, 54(11), 2907–2926. doi:10.1007/s40279-024-02077-2

[22] BLOG Runmefit. Cómo utilizar los smartwatches para mejorar la calidad de vida de las personas mayores: 7 funciones útiles que debes conocer. <https://runmefit.com/es/blog/como-utilizar-los-smartwatches-para-mejorar-la-calidad-de-vida-de-las-personas-mayores-7-funciones-utiles-que-debes-conocer/>

[23] Cátedra Cuatroochenta de Inteligencia Artificial, Salud y Bienestar de la Universitat Jaume I. Proyecto Senior monitoring. Localización y detección integrada para el seguimiento digital de la actividad humana (INDRI). Proyecto financiado por el Ministerio de Ciencia e Innovación. Código: PID2021-122642OB-C44. Plazo de ejecución: del 01/09/2022 al 31/08/2025. <https://catedra.cuatroochenta.com/senior-monitoring/>

[24] Razjouyan, J., Naik, AD, Horstman, MJ, Kunik, ME, Amirmazaheri, M., Zhou, H., Sharafkhaneh, A. y Najafi, B. (2018). Sensores portátiles y la evaluación de la fragilidad en adultos mayores vulnerables: un estudio de cohorte observacional. *Sensors* , 18 (5), 1336. <https://doi.org/10.3390/s18051336>

[25] Schmidle, S., Gulde, P., Koster, R., Soaz, C., & Hermsdörfer, J. (2023). The relationship between self-reported physical frailty and sensor-based physical activity measures in older adults - a multicentric cross-sectional study. *BMC geriatrics*, 23(1), 43. <https://doi.org/10.1186/s12877-022-03711-2>

[26] Arantes, F. S., Rosa Oliveira, V., Leão, A. K. M., Afonso, J. P. R., Fonseca, A. L., Fonseca, D. R. P., Mello, D. A. C. P. G., Costa, I. P., Oliveira, L. V. F., & da Palma, R. K. (2022). Heart rate variability: A biomarker of frailty in older adults?. *Frontiers in medicine*, 9, 1008970. <https://doi.org/10.3389/fmed.2022.1008970>

[27] Agrawal, R., Hu, A., y Bollag, WB (2023). La piel y el envejecimiento inflamatorio. *Biología* , 12 (11), 1396. <https://doi.org/10.3390/biology12111396>

[28] Jude, Titi. (2024). Machine Learning Applications in Wearable Health Monitoring. [https://www.researchgate.net/publication/388263285\\_Machine\\_Learning\\_Applications\\_in\\_Wearable\\_Health\\_Monitoring](https://www.researchgate.net/publication/388263285_Machine_Learning_Applications_in_Wearable_Health_Monitoring)

[29] Chen, T., & Guestrin, C. (2016). *XGBoost: A scalable tree boosting system*. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). <https://doi.org/10.1145/2939672.2939785>

[30] Polar. (2018). *Polar Open AccessLink Python Example* [Software]. Recuperado de <https://github.com/polarofficial/accesslink-example-python>

# 11 Anexos

**ANEXO A.** Todo el código desarrollado para el trabajo se encuentra en GitHub:  
<https://github.com/tfgLuz/EstimacionDeLaFragilidad/tree/main>

**ANEXO B.** Función del script `clasificacion_fragilidad.py`, que aplica un sistema de puntuación basado en reglas, inspirado en los criterios del fenotipo de la fragilidad.

```
def classify_frailty_by_rules(row):  
    """  
    Aplica un sistema de puntuación basado en reglas para clasificar  
    una fila de datos.  
    Puntuación: 2 (Robusto), 1 (Pre-frágil), 0 (Frágil)  
    """  
    score = 0  
  
    # 1. Pasos Activos (Métrica de Actividad)  
    if row['active-steps'] > 6000:  
        score += 2  
    elif row['active-steps'] > 2500:  
        score += 1  
  
    # 2. Variabilidad de la Frecuencia Cardíaca (Métrica de Resiliencia  
    Fisiológica)  
    if row['heart_rate_variability_avg'] > 35:  
        score += 2  
    elif row['heart_rate_variability_avg'] > 25:  
        score += 1  
  
    # 3. Frecuencia Cardíaca Media Nocturna (Métrica de Estrés  
    Fisiológico)  
    if row['heart_rate_avg'] < 65:  
        score += 2  
    elif row['heart_rate_avg'] < 72:  
        score += 1  
  
    # 4. Puntuación del Sueño (Métrica de Calidad del Descanso)  
    if row['sleep_score'] > 75:  
        score += 2  
    elif row['sleep_score'] > 60:  
        score += 1  
  
    # --- Clasificación Final basada en la Puntuación Total (Máximo 8  
    puntos) ---  
    if score >= 6:  
        return 'robusto'  
    elif score >= 3:  
        return 'pre-fragil'  
    else:  
        return 'fragil'
```